

## 6.6 Las losowy

Zaimplementuj uczenie lasu losowego na bazie redukcji Gini(8) zakładając że prawdopodobieństwo wystąpienia klasy jest wprost proporcjonalne do proporcji występowania jej próbek w zbiorze danych. Przy implementacji należy pamiętać o procedurze **"bagging'u", losowym wyborze cech na węzłach** oraz o **wyborze wielkości lasu w oparciu o błąd OOB (Out-Of-Bag)** - las losowy **nie jest** komitetem drzew decyzyjnych.

$$G = 1 - \sum_i p_i^2 \quad (8)$$

- $G \in [0, 1]$  współczynnik różnorodności Gini'ego
- $p_i \in [0, 1]$  prawdopodobieństwo  $i$ -tej klasy

Wytrenuj klasyfikator na **syntetycznych zbiorach jednomodowych** oraz **syntetycznym zbiorze wielomodowym** i porównaj jego działanie z gotowym algorytmem `sklearn.ensemble.RandomForestClassifier`.

Wykorzystując zbiór NASA JPL Asteroid i algorytm `sklearn.model_selection.GridSearchCV` dobierz optymalny zestaw hiperparametrów struktury lasu (`n_estimators`, `criterion`, `max_depth`, `min_samples_split` oraz `min_samples_leaf`) i naucz las losowy (z `sklearn`) detekcji obiektów bliskich ziemi (NEO). Pamiętaj o usunięciu pól `Orbit_id` i `full_name`. Powtórz proces dla detekcji potencjalnie niebezpiecznych obiektów (PHA), czy wybrane zostały takie same hiperparametry? Optymalizacja hiperparametrów musi być poprzedzona poprawnym preprocessingiem zbioru danych.

Wykorzystując zbiór NASA JPL Asteroid zbadaj wpływ wielkości lasu na szybkość inferencji oraz skuteczność modelu z `sklearn` i własnej implementacji w problemie detekcji obiektów bliskich ziemi (NEO). Pomiar skuteczności i szybkości powinien być powtórzony przynajmniej 5 razy dla każdej wielkości.

### 6.6.1 Kryteria oceniania

Implementacja lasu losowego  $\rightarrow 3$

Analiza zbioru NASA JPL Asteroid w oparciu o las losowy  $\rightarrow 4$

Analiza wpływu wielkości lasu na jego skuteczność  $\rightarrow 5$